UNIVERSITATEA BABEŞ-BOLYAI

Facultatea de Ştiinţe Economice şi Gestiunea Afacerilor

Statistică și Previziune Economică

Lucrare de licență

Absolvent,

Mădălina-Mihaela **NOUR**

Coordonator ştiinţific,

Prof. univ. dr. Gabriela **OLTEANU**

2026

UNIVERSITATEA BABEŞ-BOLYAI

Facultatea de Ştiinţe Economice şi Gestiunea Afacerilor

Statistică și Previziune Economică

Lucrare de licență

Lanțurile Markov și aplicațiile lor în detectarea tranzacțiilor frauduloase

Absolvent,

Mădălina-Mihaela **NOUR**

Coordonator ştiinţific,

Prof. univ. dr. Gabriela **OLTEANU**

2026

Rezumat

Lucrarea analizează aplicabilitatea Modelelor Markov cu Stări Ascunse (HMM) în detectarea tranzacțiilor bancare frauduloase, în contextul accelerării digitalizării plăților electronice în România. Cadrul teoretic prezintă conceptele fundamentale privind lanțurile Markov, parametrii HMM și algoritmii de estimare. Din perspectivă empirică, s-a construit un istoric tranzacțional sintetic, iar algoritmii TwoStep Cluster și K-Means au fost utilizați pentru discretizarea datelor financiare. Modelele HMM Gaussian și Multinomial au fost antrenate pe seturi de 100 și 500 de tranzacții, iar performanța lor a fost comparată prin matricea de confuzie, curba ROC și indicatorul AUROC. Rezultatele demonstrează că modelul Gaussian antrenat pe 100 de observații reprezintă configurația optimă, oferind un echilibru între performanță globală (AUROC = 0.9165), flexibilitate în ajustarea pragului de alertă și efort computațional redus, cu implicații directe pentru scalabilitatea sistemelor de securitate financiară.

Cuprins

Abrevieri ... **iv**
Lista tabelelor şi figurilor ... **v**
Introducere ... **6**
1. Cadru teoretic ... **8**
1.1 Lanțuri Markov ... 8
1.2 Model Markov cu stări ascunse ... 9
1.2.1 Parametrii HMM ... *10*
1.2.2 Modelul Multinomial ... *10*
1.2.3 Modelul Gaussian ... *11*
1.3 Algoritmul TwoStep Cluster ... 12
1.4 Algoritmul K-Means ... 13
1.5 Metoda de estimare a parametrilor ... 13
1.5.1 Metoda verosimilității maxime ... *13*
1.5.2 Algoritmul Expectation-Maximization ... *14*
1.5.3 Algoritmul Forward-Backward ... *15*
1.6 Criterii de selecție a modelelor ... 15
1.6.1 Matricea de confuzie ... *15*
1.6.2 Curba ROC și indicatorul AUROC ... *16*
2. Cadru metodologic ... **17**
2.1 Generarea și structurarea datelor ... 17
2.2 Optimizarea numărului de clustere ... 18
2.3 Discretizarea tranzacțiilor prin algoritmul K-Means ... 18
2.4 Metoda de estimare a parametrilor ... 19
2.5 Metodologia de detecție a anomaliilor ... 19
2.6 Evaluarea performanței modelului ... 20
3. Studiu de caz ... **21**
3.1 Generarea și explorarea datelor tranzacționale ... 21
3.2 Evaluarea numărului optim de stări (TwoStep Cluster) ... 23
3.3 Discretizarea datelor și stabilirea clusterelor ... 24
3.4 Estimarea parametrilor: exemplu practic ... 26
3.4.1 Definirea parametrilor inițiali ... *27*
3.4.2 Secvența de observații și calculul rutelor intermediare ... *27*
3.5 Analiza parametrilor modelelor ... 30
3.5.1 Parametrii modelului Gaussian ... *30*
3.5.2 Parametrii modelului Multinomial ... *32*
3.6 Simularea detaliată a unei alerte ... 33
3.7 Rezultatele detecției de anomalii ... 35
3.8 Evaluarea performanței globale ... 36
3.9 Selecția modelului optim ... 37
Concluzii ... **39**
Bibliografie ... **41**
Anexe ... **42**

Abrevieri

AUROC,	aria de sub curba ROC (Area Under the Receiver Operating Characteristic)
EM,	algoritmul de maximizare a așteptărilor (Expectation-Maximization)
FN,	fals negative (False Negatives)
FP,	fals pozitive (False Positives)
FPR,	rata alarmelor false (False Positive Rate)
HMM,	model Markov cu stări ascunse (Hidden Markov Model)
MLE,	metoda verosimilității maxime (Maximum Likelihood Estimation)
ROC,	caracteristica de operare a receptorului (Receiver Operating Characteristic)
TN,	adevărat negative (True Negatives)
TP,	adevărat pozitive (True Positives)
TPR,	rata rezultatelor adevărat pozitive (True Positive Rate)

Lista tabelelor şi figurilor

Tabele:

Tabel 1. Setul de 100 de tranzacții generate (exprimate în RON) 21
Tabel 2. Statisticile descriptive comparative pentru seturile de date simulate 22
Tabel 3. Centrele inițiale ale clusterelor (100 de observații) 25
Tabel 4. Istoricul iterațiilor (100 de observații) 25
Tabel 5. Rezultatele algoritmului K-Means (100 de observații) 25
Tabel 6. Rezultatele algoritmului K-Means (500 de observații) 25
Tabel 7. Matricea de tranziție 27
Tabel 8. Matricea de emisie 27
Tabel 9. Tabelul de analiză pentru întregul șir de tranzacții 28
Tabel 10. Matricea de tranziție (Pseudo-probabilități) 28
Tabel 11. Calculul pseudo-probabilității $P(L|S_2)$ 29
Tabel 12. Matricea de emisie (Pseudo-probabilități) 29
Tabel 13. Matricea de tranziție (Normalizată) 30
Tabel 14. Matricea de emisie (Normalizată) 30
Tabel 15. Matricea de confuzie aferentă modelului Multinomial 35
Tabel 16. Matricea de confuzie aferentă modelului Gaussian 35
Tabel 17. Valorile indicatorului AUROC 36
Tabel 18. Sinteza comparativă a modelelor HMM 38

Figuri:

Figura 1. Lanț Markov 9
Figura 2. Model Markov cu stări ascunse 11
Figura 3. Distribuția emisiilor Gaussiene pentru stările latente 12
Figura 4. Histograma aferentă setului de 100 de tranzacții 22
Figura 5. Histograma aferentă setului de 500 de tranzacții 23
Figura 6. Algoritmul TwoStep Cluster pe setul de 100 de tranzacții 24
Figura 7. Algoritmul TwoStep Cluster pe setul de 500 de tranzacții 24
Figura 8. Frecvența tranzacțiilor pe clustere 26
Figura 9. Frecvența tranzacțiilor pe clustere 26
Figura 10. Distribuția normală a tranzacțiilor din Starea 2 31
Figura 11. Suprapunerea distribuțiilor pentru Starea 2 și Starea 3 31
Figura 12. Curba ROC 36

Introducere

Digitalizarea rapidă a sectorului bancar din România a condus la o adoptare pe scară largă a plăților electronice. Conform cercetării de piață „Sistemul bancar în percepția românilor: creditarea și incluziunea financiară a românilor", realizată în anul 2024, majoritatea populației incluse financiar și majoritatea companiilor folosesc deja serviciile de internet și mobile banking. Datele arată o evoluție clară în această direcție, plățile digitale înregistrând o creștere de 11% față de nivelul raportat în anul 2022. Mai mult, aproximativ 37% dintre persoanele fizice confirmă că în prezent utilizează cardul fie în mod exclusiv, fie ca metodă principală de plată.

Odată cu extinderea la nivel global a utilizării cardurilor bancare, cresc exponențial și oportunitățile atacatorilor de a sustrage date financiare și de a iniția tranzacții frauduloase. Raportul asupra stabilității financiare din decembrie 2025, publicat de Banca Națională a României (BNR), subliniază că riscurile legate de siguranța plăților sunt strâns legate de fenomenul fraudei, care a devenit o amenințare constantă, aflată în continuă schimbare. Prin monitorizarea serviciilor de plată, BNR încearcă să identifice cele mai frecvente și recente scenarii de fraudă pentru a propune măsuri de prevenție și detectare cât mai eficiente. Datele pot fi compromise prin multiple metode, printre care se numără mesajele înșelătoare de tip smishing sau tehnicile de spoofing. Acestea din urmă presupun falsificarea unor elemente de identificare, precum adresa de e-mail, numele expeditorului sau numărul de telefon. Scopul este convingerea victimei că interacționează cu o sursă de încredere pentru a o determina să ofere date financiare confidențiale (coduri PIN, parole, datele cardului) sau să autorizeze tranzacții.

Pentru a contracara amenințările menționate, băncile au nevoie de soluții tehnice moderne, capabile să recunoască tiparul tranzacțional obișnuit al fiecărui utilizator, astfel încât orice plată suspectă să poată fi identificată rapid. În acest context, lanțurile Markov reprezintă o soluție eficientă, fiind un concept clasic al statisticii care își dovedește în continuare aplicabilitatea în domeniul securității financiare. Într-un model standard, ar trebui cunoscută intenția reală a utilizatorului în momentul efectuării unei plăți, însă instituțiile financiare au acces doar la datele referitoare la sumele tranzacționate. Deoarece contextul sau starea în care se află clientul nu sunt vizibile direct, acestea sunt considerate elemente „ascunse". Pentru a depăși această limitare și a modela comportamentul tranzacțional, se poate utiliza un Model Markov cu Stări Ascunse (HMM), care poate deduce aceste intenții ascunse analizând exclusiv

datele observabile, adică succesiunea sumelor tranzacționate. Relevanța acestei abordări în detectarea fraudelor bancare este confirmată și de literatura de specialitate (Bhusari și Patil, 2011).

Scopul acestei lucrări este dezvoltarea unui sistem de detecție bazat pe un astfel de model, care identifică profilul de cheltuieli legitim al clientului pe baza istoricului său. Prin evaluarea probabilității ca o nouă secvență să aparțină tiparului învățat, modelul propus semnalează apariția unei anomalii. Acest semnal de deviație poate fi ulterior preluat de sistemele operaționale ale băncii pentru a declanșa alerte de securitate și a bloca tranzacțiile, minimizând astfel riscul de pierderi financiare.

Intenția inițială a fost analizarea unui singur model de detecție. Totuși, pentru a optimiza performanța sistemului și a fundamenta solid alegerea finală, pe parcurs am optat pentru o abordare comparativă. Astfel, comparând diferite configurații în funcție de natura distribuțiilor de emisie și de mărimea eșantionului folosit la antrenare, s-au obținut argumente clare care arată de ce modelul ales în final este potrivit pentru mediul bancar.

Lucrarea este organizată după cum urmează: Capitolul 1 prezintă noțiunile fundamentale legate de lanțurile Markov și modelele cu stări ascunse, oferind baza teoretică necesară pentru a înțelege aplicarea acestora în detectarea fraudelor. Capitolul 2 descrie fundamentul metodologic utilizat, detaliind etapele de simulare a datelor financiare și rolul algoritmilor de clusterizare, făcând astfel trecerea de la conceptele teoretice la testarea lor concretă. Capitolul 3 prezintă rezultatele experimentale, analizând comparativ performanțele modelelor HMM Gaussian și Multinomial și evaluând impactul lungimii istoricului tranzacțional asupra preciziei detecției. În final, sunt prezentate concluziile cercetării și direcțiile viitoare de studiu, iar tabelul ce conține istoricul extins de tranzacții este inclus în secțiunea de anexe.

1. Cadru teoretic

În cadrul acestui capitol, mi-am propus să prezint noțiunile fundamentale legate de lanțurile Markov, având la bază lucrarea lui Norris (1998). Consultând literatura de specialitate, am organizat abordările reprezentative privind modelele cu stări ascunse și estimarea parametrilor, având ca reper principal studiul lui Rabiner și Juang (2003). De asemenea, capitolul detaliază metoda K-Means pentru prelucrarea datelor, urmată de criteriile de evaluare a performanței. Această bază oferă reperele teoretice necesare pentru a înțelege modul în care aceste concepte matematice sunt aplicate în detectarea tranzacțiilor frauduloase.

1.1 Lanțuri Markov

Un lanț Markov este un proces stohastic ce descrie o succesiune de evenimente. Probabilitatea de apariție a unui nou eveniment este determinată strict pe baza stării imediat anterioare, ignorând întregul istoric de date. Întrucât starea curentă este efectul direct al tuturor evenimentelor din trecut, ea conține deja informația necesară pentru a calcula probabilitatea pasului imediat următor. Astfel, predicțiile realizate sunt la fel de precise precum cele obținute cunoscând întreaga evoluție a procesului. Această caracteristică fundamentală poartă numele de „proprietate Markov” și se exprimă matematic astfel:

$$P(X_{n+1}=x \mid X_1=x_1, X_2=x_2, ..., X_n=x_n) = P(X_{n+1}=x \mid X_n=x_n)$$

Pentru a modela un astfel de proces, sistemul analizat este definit printr-o mulțime finită de condiții sau situații distincte în care se poate afla la un moment dat, cunoscute sub denumirea de stări ($S = \{S_1, S_2, ..., S_N\}$). Pe măsură ce timpul avansează, sistemul trece dintr-o stare în alta, realizând o tranziție.

Datorită capacității lor de a modela procese complexe, lanțurile Markov sunt utilizate într-o gamă vastă de domenii, pornind de la biologie și chimie până la economie și finanțe.

În contextul comportamentului financiar, putem defini mulțimea stărilor ca fiind diferitele profiluri de cheltuieli prin care trece un utilizator de card în momentul în care realizeaza o tranzacție. De exemplu, putem presupune următorul profil:

- Cheltuieli de bază (S_1): Plăți recurente efectuate de obicei în anumite perioade ale lunii și caracterizate prin sume mai mari (de exemplu: rate, chirii);

• Cheltuieli zilnice (S_2): Cheltuieli de rutină cu o frecvență ridicată și sume relativ mici (de exemplu: cumpărături alimentare, transport);

• Cheltuieli ocazionale (S_3): Achiziții excepționale caracterizate de sume medii sau mari și o apariție neregulată (de exemplu: vacanțe, electronice);

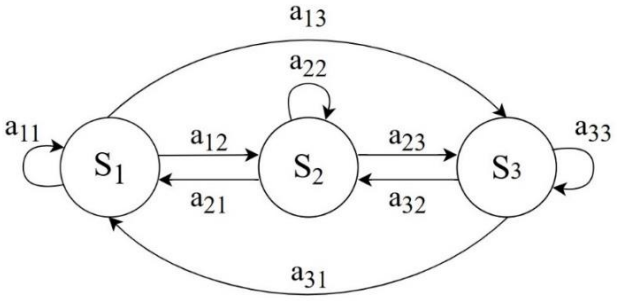


Figura 1. Lanț Markov

Comportamentul normal al utilizatorului poate fi reprezentat ca o trecere fluidă de la un anumit profil de cheltuieli la altul. Această dinamică nu este aleatoare, ci este descrisă de o matrice de tranziție (A), unde fiecare trecere între două stări are atașată o anumită probabilitate.

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

$$a_{ij} = P(X_{n+1} = S_j \mid X_n = S_i)$$

În cadrul acestei matrice, fiecare rând corespunde stării actuale, iar fiecare coloană reprezintă starea viitoare. Elementul a_{ij} indică probabilitatea de tranziție de la starea i la starea j. Suma elementelor de pe fiecare rând este egală cu 1.

$$\sum_{j=1}^{n} a_{ij} = 1$$

1.2 Model Markov cu stări ascunse

Modelele Markov cu stări ascunse (HMM) sunt modele statistice în care observațiile rezultate depind de un lanț Markov latent. HMM depinde de două procese stohastice: un proces observabil și unul ascuns. Procesul ascuns, notat cu X, trece printr-o serie de stări latente ($X = \{x_1, x_2, x_3\}$) conform unor probabilități de tranziție. Aceste stări nu pot fi văzute de un observator extern. În schimb, procesul observabil (Y) emite o secvență de observații ($O = \{y_i, y_i, y_i, y_i, ... \}$) care depinde de procesul ascuns cu o anumită probabilitate. Așadar, procesul ascuns poate fi dedus doar analizând procesul observabil.

1.2.1 Parametrii HMM

Pentru a fi definit complet, un HMM necesită stabilirea unui set de parametri, notat sub forma $\lambda = \{A, B, \pi\}$.

Primul element, matricea de tranziție (A), păstrează rolul definit anterior în cadrul lanțurilor Markov. Aceasta cuantifică probabilitatea ca sistemul să treacă dintr-o stare ascunsă în alta la momente succesive de timp, fiind exprimată matematic astfel:

$$a_{ij} = P(X_{n+1} = x_j \mid X_n = x_i)$$

Un alt element al setului de parametri specifică starea de plecare a sistemului. Acest aspect este definit prin vectorul probabilităților inițiale (π), unde $P(X_1 = x_i)$ reprezintă probabilitatea ca succesiunea de evenimente să debuteze în starea x_i.

$$\pi = \{P(X_1 = x_1), P(X_1 = x_2), P(X_1 = x_3)\}$$

Definirea parametrului de emisie a observațiilor (B) impune o distincție metodologică importantă. În funcție de natura procesului de emisie (discret sau continuu), există multiple variante ale HMM. Această lucrare se concentrează pe doar două dintre acestea: HMM Multinomial și HMM Gaussian.

1.2.2 Modelul Multinomial

Modelul Multinomial este utilizat atunci când observațiile generate de sistem sunt variabile categoriale, aparținând unei mulțimi discrete și finite (Carlson et al., 2021). În contextul detectării fraudelor, sumele tranzacționate sunt grupate în categorii predefinite.

În această lucrare s-a optat pentru următoarele notații referitoare la categoriile de tranzacții:

- L (low) - pentru tranzacții de valoare mică;
- M (medium) – pentru tranzacții de valoare medie;
- H (high) – pentru tranzacții de valoare mare.

Deoarece se lucrează cu aceste date discrete, parametrul de emisie a observațiilor (B) ia forma unei matrice de probabilități. În structura acestei matrice, fiecare rând corespunde unei stări latente (i), iar fiecare coloană reprezintă categoria emisă ca observație (j). Astfel, fiecare element b_{ij} reprezintă probabilitatea condiționată ca sistemul, aflându-se în starea x_i, să genereze rezultatul observabil y_j. Formularea matematică a matricei de emisie este următoarea:

$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix}$$

$$b_{ij} = P(Y_n = y_j \mid X_n = x_i)$$

Relația dintre stările latente și probabilitățile de emisie a acestor categorii este ilustrată în figura următoare:

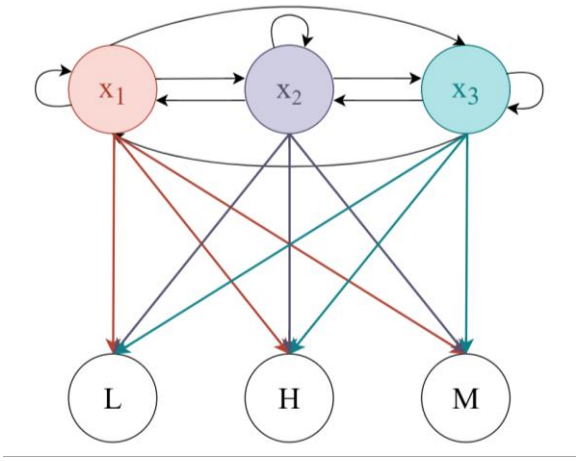


Figura 2. Model Markov cu stări ascunse

1.2.3 Modelul Gaussian

Modelul HMM Gaussian este utilizat atunci când datele observate sunt variabile numerice continue. În contextul securității bancare, această abordare permite procesarea directă a sumelor tranzacționate.

Conform studiului realizat de Nkemnole și Akinsete (2021), care a evaluat performanța mai multor distribuții în detecția fraudelor, utilizarea unei distribuții Gaussiene pentru modelarea emisiilor reprezintă cea mai eficientă soluție tehnică.

Acest model se bazează pe ipoteza că observațiile emise din fiecare stare latentă urmează o distribuție normală (Gaussiană). Din acest motiv, probabilitatea emisiilor este determinată de o funcție de densitate de probabilitate.

Pentru fiecare stare ascunsă x_i, probabilitatea de a observa o tranzacție cu valoarea O_t este calculată prin formula „clopotului lui Gauss”:

$$b_i(O_t) = \frac{1}{\sigma_i\sqrt{2\pi}} e^{-\frac{(O_t-\mu_i)^2}{2\sigma_i^2}}$$

În această ecuație, emisiile fiecărui profil de cheltuieli sunt caracterizate de doi parametri:

- Media (μ_i): reprezintă valoarea centrală sau nivelul „așteptat” al tranzacțiilor pentru starea respectivă.
- Abaterea standard (σ_i): măsoară gradul de dispersie a tranzacțiilor în jurul mediei. O abatere standard mică indică sume relativ constante și previzibile, în timp ce o valoare ridicată reflectă o variabilitate pronunțată a cheltuielilor.

Astfel, parametrul de emisie B este reprezentat sub forma unei matrice care grupează perechile de parametri (μ, σ) pentru toate stările ascunse ale sistemului. Pentru un sistem cu trei stări ascunse, structura generală a matricei B este următoarea:

$$B = \begin{bmatrix} \mu_1 & \sigma_1 \\ \mu_2 & \sigma_2 \\ \mu_3 & \sigma_3 \end{bmatrix}$$

Reprezentarea grafică a acestor parametri este ilustrată în Figura 3.

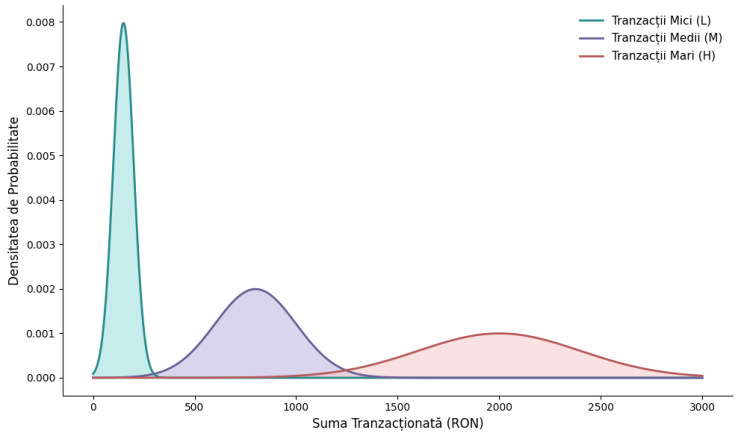


Figura 3. Distribuția emisiilor Gaussiene pentru stările latente

Fiecare curbă corespunde unei stări latente, forma sa fiind dictată direct de media (μ) și abaterea standard (σ) aferente:

- Tranzacțiile mici (L): Prezintă o abatere standard minimă, generând o curbă înaltă și îngustă.
- Tranzacțiile medii (M): Au o dispersie moderată, curba fiind mai largă și centrată pe valori medii.
- Tranzacțiile mari (H): Sunt caracterizate de o variabilitate ridicată. Clopotul este puternic aplatizat și extins pe un interval larg.

1.3 Algoritmul TwoStep Cluster

Algoritmul TwoStep Cluster este o metodă avansată de analiză, concepută pentru a identifica automat numărul optim de grupuri dintr-un set de date. Funcționarea sa implică două etape: o pre-clusterizare care grupează rapid observațiile similare pentru a reduce volumul de calcul, urmată de o clusterizare ierarhică a acestor sub-grupuri. Numărul ideal de clustere este determinat statistic prin evaluarea Criteriului Informațional Bayesian, care caută echilibrul între complexitatea partiției și acuratețea acesteia. Adițional, performanța grupării este măsurată prin scorul Silhouette, un indicator care evaluează gradul de asemănare a datelor din același cluster și separarea acestuia față de restul grupurilor.

1.4 Algoritmul K-Means

Algoritmul K-Means este o metodă de grupare prin care un număr de observații (n) sunt împărțite într-un număr prestabilit de clustere (k), fiecare tranzacție fiind repartizată grupului cu cea mai apropiată medie (centroid). Această tehnică se bazează pe minimizarea varianței din interiorul clusterelor, permițând crearea unor grupuri omogene de date (MacQueen, 1967).

Conform abordării descrise de Srivastava et al. (2008), pentru a implementa acest model la scară reală, algoritmul de grupare trebuie rulat pe istoricul tranzacțional al fiecărui client în parte. Comportamentul financiar diferă de la un deținător de card la altul, așadar intervalele care definesc diferitele niveluri de sume (tranzacții mici, medii sau mari) variază semnificativ.

Pentru a realiza această grupare, algoritmul K-Means funcționează iterativ, parcurgând trei pași. În etapa de inițializare, se definesc k=3 puncte de referință (centroizi), corespunzătoare celor trei tipuri de tranzacții dorite (L, M, H). Urmează etapa de alocare, în care fiecare sumă tranzacționată din istoricul clientului este atribuită celui mai apropiat centroid pe baza distanței euclidiene. În final, are loc etapa de actualizare, unde poziția fiecărui centroid este recalculată ca fiind media aritmetică a tuturor sumelor care alcătuiesc grupul respectiv. Procesul de alocare și actualizare se repetă succesiv până la atingerea convergenței, adică momentul în care nicio tranzacție nu își mai schimbă apartenența.

1.5 Metoda de estimare a parametrilor

Identificarea fraudelor, privite ca deviații de la un tipar, necesită cunoașterea prealabilă a comportamentului obișnuit. Prin urmare, primul pas în detectarea lor constă în antrenarea modelului HMM pentru a învăța profilul tranzacțional normal al deținătorului de card. Acest proces de antrenare constă în estimarea parametrilor optimi ai modelului (λ).

1.5.1 Metoda verosimilității maxime

Metoda verosimilității maxime (MLE) presupune identificarea acelor parametri care maximizează probabilitatea ca modelul să fi generat datele observate.

Pentru a înțelege cum funcționează estimarea, definim funcția de verosimilitate $L(\lambda)$. Aceasta reprezintă probabilitatea ca secvența de tranzacții observată $O = \{O_1, O_2, ..., O_T\}$ să fie generată de modelul cu parametrii λ:

$$L(\lambda) = P(O_1, O_2, ..., O_T \mid \lambda)$$

În practică, se preferă maximizarea log-verosimilității (ln L(λ)), deoarece transformă produsele de probabilități în sume, facilitând calculul derivatelor și evitând valorile numerice extrem de mici:

$$\ln L(\lambda) = \ln P(O \mid \lambda)$$

Însă, în cazul HMM, probabilitatea P(O | λ) depinde de secvența de stări ascunse X = {x1, x2, ..., xT}, pe care nu o cunoaștem. Așadar, verosimilitatea se calculează prin însumarea probabilităților tuturor succesiunilor posibile de stări:

$$P(O \mid \lambda) = \sum_{X} P(O, X \mid \lambda)$$

Pentru a evalua o singură succesiune, se înmulțesc probabilitatea inițială, probabilitățile de tranziție și cele de emisie:

$$P(O, X \mid \lambda) = \pi_{x1} b_{x1}(O_1) \prod_{t=2}^{T} a_{x_{t-1}x_t} b_{x_t}(O_t)$$

Deoarece numărul combinațiilor posibile de stări crește exponențial în raport cu lungimea secvenței, rezolvarea prin calcul direct devine impractică și ineficientă..

Pentru a depăși această limitare, se utilizează algoritmul Expectation-Maximization (EM), a cărui implementare specifică pentru modelele HMM poartă denumirea de algoritmul Baum-Welch.

1.5.2 Algoritmul Expectation-Maximization

Algoritmul EM este o metodă statistică utilizată pentru estimarea parametrilor în sisteme cu variabile latente. După atribuirea unor valori inițiale pentru λ, procesul decurge iterativ prin doi pași interdependenți (Ng, 2023):

- Pasul E (estimarea valorilor așteptate): Pe baza parametrilor curenți, modelul estimează probabilitatea ca sistemul să se afle într-o anumită stare pentru fiecare tranzacție observată. În cazul modelelor HMM, acest pas este realizat eficient prin intermediul algoritmului Forward-Backward.
- Pasul M (maximizarea verosimilității): Parametrii sunt calculați aplicând MLE folosind estimările de la pasul anterior ca și cum ar fi date certe.

Procesul se repetă până la convergență, respectiv până când parametrii se stabilizează și verosimilitatea nu mai poate fi îmbunătățită semnificativ.

1.5.3 Algoritmul Forward-Backward

Algoritmul Forward-Backward rezolvă problema evaluării stărilor ascunse analizând secvența de tranzacții din ambele direcții. Scopul lui este să calculeze probabilitatea exactă de a fi într-o anumită stare la momentul t, luând în calcul toate observațiile din secvență (O_1, O_2, ..., O_T). Pentru a fi eficient și a evita calcularea tuturor combinațiilor, algoritmul împarte problema în două părți:

- Pasul Forward: Parcurge secvența cronologic, de la prima tranzacție (t=1) până la momentul de referință (t). Calculează probabilitatea de a observa tranzacțiile trecute și de a ajunge în starea respectivă.
- Pasul Backward: Parcurge secvența invers, de la ultima tranzacție (T) înapoi la momentul de referință (t). Calculează probabilitatea de a observa restul tranzacțiilor, presupunând că pornim din starea de la momentul t.

1.6 Criterii de selecție a modelelor

1.6.1 Matricea de confuzie

Pentru a evalua acuratețea HMM în detectarea tranzacțiilor frauduloase, deciziile algoritmului sunt clasificate folosind matricea de confuzie. Aceasta împarte rezultatele în patru categorii fundamentale:

- Adevărat Pozitive (True Positives - TP): Tranzacții frauduloase care au fost corect identificate și respinse de model.
- Fals Pozitive (False Positives - FP): Tranzacții normale care au fost în mod eronat etichetate drept fraudă de către model (alarme false).
- Adevărat Negative (True Negatives - TN): Tranzacții normale care au fost acceptate corect de sistem.
- Fals Negative (False Negatives - FN): Tranzacții frauduloase care au reușit să treacă nedetectate, modelul acceptându-le ca fiind normale.

Pe baza acestor indicatori, se calculează metrici de performanță pentru a compara robustețea modelelor:

- Sensibilitatea (True Positive Rate - TPR): Calculează proporția de fraude reale care au fost detectate corect. Un model ideal trebuie să aibă o sensibilitate cât mai apropiată de 100%.

$$\text{TPR} = \frac{TP}{TP + FN}$$

- Rata alarmelor false (False Positive Rate - FPR): Reprezintă proporția de tranzacții legitime care au fost respinse eronat. Pentru a nu afecta experiența utilizatorului, această rată trebuie menținută la un nivel cât mai scăzut.

$$\text{FPR} = \frac{FP}{FP + TN}$$

1.6.2 Curba ROC și indicatorul AUROC

Curba ROC (Receiver Operating Characteristic) este un grafic care ilustrează performanța unui model de clasificare binară la diverse valori ale pragului de decizie (James et al., 2013). În analiza tranzacțiilor, acest prag reprezintă valoarea de la care sistemul decide să separe operațiunile legitime de cele suspecte, marcând momentul în care se declanșează o alertă. Curba este construită prin reprezentarea Sensibilității (TPR) în raport cu Rata alarmelor false (FPR) pentru fiecare setare a acestui nivel limită. Principalul avantaj al analizei ROC este că oferă instrumentele necesare pentru a selecta modelele optime.

Pentru a permite o comparație obiectivă între diferiți algoritmi, performanța curbei ROC este sintetizată printr-un singur indicator: aria de sub curbă (AUROC). În contextul securității bancare, un AUROC cât mai apropiat de valoarea maximă confirmă eficiența modelului HMM.

2. Cadru metodologic

În cadrul acestui capitol, mi-am propus să descriu fundamentul metodologic utilizat pentru implementarea sistemului de detectare a fraudelor. Am detaliat etapele de simulare a datelor financiare, abordarea privind volumul optim al observațiilor fiind fundamentată pe cercetarea lui Srivastava et al. (2008). Totodată, am stabilit modul în care tehnicile de clusterizare sunt folosite pentru pregătirea variabilelor, aplicând algoritmul TwoStep Cluster (Bacher, Wenzig și Vogler, 2004), și am descris procesul de estimare a parametrilor utilizând pachetul depmixS4 din mediul R (Visser și Speekenbrink, 2010). Practic, acest capitol face legătura dintre conceptele teoretice și testarea lor concretă.

În acest sens, o componentă centrală a analizei o constituie compararea modelelor HMM Multinomial și Gaussian. Alegerea specifică a acestor două modele a fost motivată de modul diferit în care prelucrează datele financiare, fiecare aducând un compromis clar de performanță. Modelul Multinomial analizează fluxul tranzacțional prin gruparea observațiilor în categorii predefinite. Deoarece înlocuiește sumele exacte cu etichete generale, algoritmul ignoră fluctuațiile numerice mici și reduce numărul de alarme false, dar atrage riscul unei rate de detecție mai scăzute. În contrast, modelul Gaussian adoptă o abordare opusă. Deoarece evaluează direct sumele exacte, algoritmul sesizează orice abatere de la tiparul obișnuit. Această sensibilitate îi permite să maximizeze rata de detecție a fraudelor, dar vine cu dezavantajul generării mai multor alarme false. Prin urmare, testarea lor practică ne permite să stabilim obiectiv care dintre cele două variante gestionează mai bine acest echilibru într-un sistem real de securitate bancară.

2.1 Generarea și structurarea datelor

Din cauza confidențialității datelor bancare reale, a fost necesară simularea unui istoric tranzacțional folosind limbajul Python (biblioteca numpy).

Studiul analizează două scenarii, utilizând seturi de date formate din 100, respectiv 500 de tranzacții. Conform cercetării realizate de Srivastava et al. (2008), pragul de 100 de secvențe este considerat optim pentru procesul de antrenare. Timpul de învățare crește abrupt peste acest nivel, având un impact negativ asupra scalabilității sistemului. Prin adăugarea setului de 500 de tranzacții, lucrarea testează ipoteza că un istoric mai lung de date îmbunătățește acuratețea

detecției. Teoretic, antrenarea modelului pe un număr mai mare de observații ar trebui să contureze mai precis tiparul real de cheltuieli, reducând astfel rata alarmelor false și justificând impactul asupra scalabilității.

Pentru a reflecta un comportament de cheltuieli realist (în care plățile de rutină sunt foarte frecvente, iar achizițiile majore sunt rare) datele au fost generate pe cinci categorii. Această distribuție a fost calibrată cu scopul de a obține o sumă verosimilă. S-a presupus că un volum de 100 de tranzacții acoperă aproximativ 3 luni din activitatea unui utilizator, în timp ce 500 de tranzacții reflectă activitatea pe un an. Astfel, concentrarea majorității tranzacțiilor în zona sumelor mici a fost necesară pentru ca suma totală simulată să reflecte un venit salarial realist. Categoriile utilizate sunt:

- 25% tranzacții foarte mici: valori generate aleator în intervalul [1, 25] RON.
- 45% tranzacții mici: valori în intervalul (25, 50] RON.
- 20% tranzacții medii: valori în intervalul (50, 350] RON.
- 6% tranzacții mari: valori în intervalul (350, 650] RON.
- 4% tranzacții foarte mari: valori în intervalul (650, 2000] RON.

După generarea categoriilor, valorile au fost integrate într-un vector și amestecate aleator utilizând funcția np.random.shuffle(). În realitate, cumpărăturile utilizatorilor de card au o anumită ciclicitate. Totuși, deoarece modelul analizează exclusiv cuantumul tranzacțiilor (omițând variabile precum data și ora), istoricul se reduce la o secvență imprevizibilă. În absența acestor date, s-a considerat că ordonarea aleatoare imită un comportament realist.

2.2 Optimizarea numărului de clustere

Pentru a stabili automat numărul optim de stări (clustere) necesare discretizării datelor financiare, s-a optat pentru utilizarea algoritmului TwoStep Cluster din mediul IBM SPSS. Validarea numărului final de clustere s-a realizat prin interpretarea scorului Silhouette, asigurând că tranzacțiile sunt împărțite în categorii omogene și bine delimitate.

2.3 Discretizarea tranzacțiilor prin algoritmul K-Means

Scopul utilizării algoritmului K-Means în cadrul acestei lucrări este să determine categoriile în care se încadrează fiecare sumă tranzacționată de un utilizator de card. Odată definite clusterele, fiecărei sume brute îi este asociată o etichetă reprezentativă (L, M sau H). Această transformare a datelor financiare continue într-o secvență de simboluri discrete este o condiție tehnică necesară pentru antrenarea variantei multinomiale a HMM.

2.4 Metoda de estimare a parametrilor

Modelele au fost definite în R, folosind pachetul depmixS4, pe baza seturilor de date generate anterior, structura codului fiind adaptată după tutorialul „Hidden Markov Model in R" de pe platforma GeeksforGeeks. Totuși, la acest stadiu, parametrii modelului, notați cu $\lambda = \{A, B, \pi\}$, nu sunt cunoscuți și trebuie estimați. Acest lucru s-a realizat prin intermediul funcției fit() care utilizează algoritmul Expectation-Maximization (EM).

2.5 Metodologia de detecție a anomaliilor

După ce parametrii modelului HMM sunt antrenați pentru a reflecta comportamentul normal al clientului, sistemul trece în faza de detecție. Când o nouă secvență de tranzacții (O) este procesată, sistemul calculează probabilitatea ca ea să aparțină acestui tipar, notată $P(O|\lambda)$. O valoare scăzută a acestei probabilități indică o deviație semnificativă de la profilul stabilit, ducând la clasificarea secvenței drept o potențială tentativă de fraudă. Această etapă se bazează pe calcularea scorului log-likelihood.

Inițial, preluăm o secvență recentă de tranzacții din istoricul utilizatorului, de o anumită lungime n. Notăm această secvență de bază cu: $O_1, O_2, ..., O_n$. Introducem secvența în modelul HMM pentru a calcula probabilitatea ca aceasta să aparțină tiparului normal, notată cu :

$$\alpha_1 = P(O_1, O_2, O_3, ..., O_n \mid \lambda)$$

În momentul în care utilizatorul inițiază o tranzacție nouă la momentul de timp următor, notată cu O_{n+1}, trebuie să testăm validitatea acesteia. Pentru a menține aceeași dimensiune a analizei, eliminăm prima tranzacție din memorie (O_1) și adăugăm noua tranzacție la final. Astfel, obținem o nouă secvență: $O_2, O_3, ..., O_{n+1}$. Calculăm din nou probabilitatea de acceptare pentru această secvență actualizată, notată cu :

$$\alpha_2 = P(O_2, O_3, O_4, ..., O_{n+1} \mid \lambda)$$

Pentru a lua o decizie privind legitimitatea tranzacției, analizăm diferența dintre cele două probabilități:

$$\Delta\alpha = \alpha_1 - \alpha_2$$

Dacă obținem $\Delta\alpha > 0$, înseamnă că modelul a acceptat noua secvență cu o probabilitate mai mică, semnalând o posibilă abatere de la comportamentul obișnuit. Totuși, pentru a confirma frauda, nu ne uităm doar la diferența brută, ci la modificarea procentuală a verosimilității. O tranzacție O_{n+1} este respinsă de bancă și ștearsă din secvență dacă raportul depășește un prag critic (threshold), stabilit empiric în faza de testare:

$$\frac{\Delta\alpha}{\alpha 1} \geq \text{prag}$$

În schimb, dacă operațiunea se află sub acest prag, este considerată legitimă și adăugată permanent în istoric. Acest mecanism asigură adaptarea continuă a modelului la evoluția comportamentului de consum al utilizatorului.

2.6 Evaluarea performanței modelului

Pentru a evalua eficacitatea modelelor HMM a fost simulată o testare sistematică pe datele generate utilizând metoda ferestrei glisante (Carlson et al., 2021). Această abordare presupune analizarea secvențială a datelor: un subset de tranzacții de o lungime fixă (fereastra) este evaluat, după care fereastra avansează cu un pas, incluzând o nouă tranzacție și eliminând-o pe cea mai veche, menținând astfel o dimensiune constantă pentru analiză.

În cadrul experimentului, fiecare model (Multinomial și Gaussian) a fost testat pe două tipuri de secvențe:

- Secvențe normale: subseturi de tranzacții extrase direct din datele generate, reprezentând comportamentul legitim al utilizatorului, pentru care s-a calculat verosimilitatea α_1.
- Secvențe frauduloase: aceleași subseturi de bază, dar în care ultima tranzacție a fost forțată artificial să ia o valoare atipică (o sumă foarte mare, corespunzătoare categoriei H), simulând astfel un atac. Pentru acestea s-a calculat verosimilitatea α_2.

Conform metodologiei detaliate anterior, decizia finală privind declanșarea unei alerte de fraudă depinde direct de compararea variației procentuale a verosimilității ($\frac{\Delta\alpha}{\alpha 1}$) cu un prag prestabilit. Deoarece nu există un prag universal valabil, performanța modelului trebuie analizată pentru multiple niveluri critice. Pentru a evalua acest compromis, s-a urmărit echilibrul dintre dorința de a maximiza Sensibilitatea (a prinde toți atacatorii) și necesitatea de a minimiza Rata alarmelor false (a nu deranja clienții legitimi). Astfel, valorile ambilor indicatori au fost calculate într-un tabel în Microsoft Excel pentru toate valorile posibile ale pragului de decizie, în intervalul [0, 1]. Aceste date stau la baza construirii Curbei ROC. Aria de sub curba ROC (AUROC) s-a calculat pe baza tabelului prin intermediul funcției AUC() din pachetul statistic DescTools. Această abordare metodologică a asigurat o bază pentru compararea performanței generale între modelele analizate.

3. Studiu de caz

În cadrul acestui capitol, mi-am propus să prezint rezultatele experimentale obținute în urma rulării modelelor statistice. Am analizat comparativ performanțele variantelor HMM Gaussian și Multinomial, evaluând impactul lungimii istoricului tranzacțional asupra preciziei detecției.

3.1 Generarea și explorarea datelor tranzacționale

Pentru antrenarea modelelor HMM a fost generat un set de date sintetice care simulează istoricul tranzacțional al unui client. Acest set a fost construit pe baza distribuțiilor descrise anterior, reflectând un comportament financiar realist.

Structura datelor de intrare este reflectată în Tabelul 1, care conține setul de 100 de observații utilizat în ambele versiuni ale modelului HMM (Gaussian și Multinomial).

Tabel 1. Setul de 100 de tranzacții generate (exprimate în RON)

Nr. tranzactiei	*Suma*	*Nr. tranzactiei*	*Suma*	*Nr. tranzactiei*	*Suma*	*Nr. tranzactiei*	*Suma*
1	44	26	163	51	1417	76	31
2	222	27	28	52	6	77	1901
3	29	28	39	53	46	78	530
4	35	29	158	54	31	79	106
5	353	30	222	55	171	80	34
6	593	31	36	56	39	81	27
7	11	32	33	57	36	82	41
8	77	33	40	58	582	83	38
9	35	34	49	59	45	84	21
10	24	35	27	60	9	85	138
11	46	36	26	61	49	86	143
12	27	37	33	62	15	87	17
13	43	38	243	63	88	88	18
14	415	39	70	64	5	89	73
15	1921	40	24	65	33	90	7
16	41	41	33	66	17	91	19
17	39	42	140	67	11	92	51
18	21	43	42	68	838	93	36
19	23	44	14	69	1	94	26
20	40	45	46	70	3	95	306
21	319	46	48	71	32	96	37
22	15	47	270	72	16	97	46
23	145	48	4	73	39	98	5
24	42	49	19	74	116	99	418
25	48	50	46	75	45	100	2

Pentru o mai bună înțelegere a profilului tranzacțional generat, datele brute au fost analizate statistic.

Tabel 2. Statisticile descriptive comparative pentru seturile de date simulate

Indicator	*N = 100*	*N = 500*
Medie	142,22	149,01
Mediană	39	38
Abatere standard	320,11	303,93
Asimetrie	4,29	3,84
Boltire	19,99	16,20
Minim	1	1
Maxim	1921	1983
Q1	24,5	24,5
Q2	39	38
Q3	101,5	131

Analiza descriptivă pentru primul eșantion, de 100 de tranzacții, confirmă că datele simulate reflectă un comportament tranzacțional dominat de plăți cu sume mici. Acest aspect este susținut de faptul că 75% dintre operațiuni (Q3) se situează sub pragul de 101,5 RON. Valoarea coeficientului de asimetrie (4,29) indică o asimetrie pozitivă, ceea ce înseamnă că vârful distribuției este deplasat spre stânga. În schimb, „coada” din dreapta este mai lungă din cauza tranzacțiilor rare de valoare mare, cu un maxim de 1921 RON. Această formă a distribuției este ilustrată vizual în histograma din Figura 4.

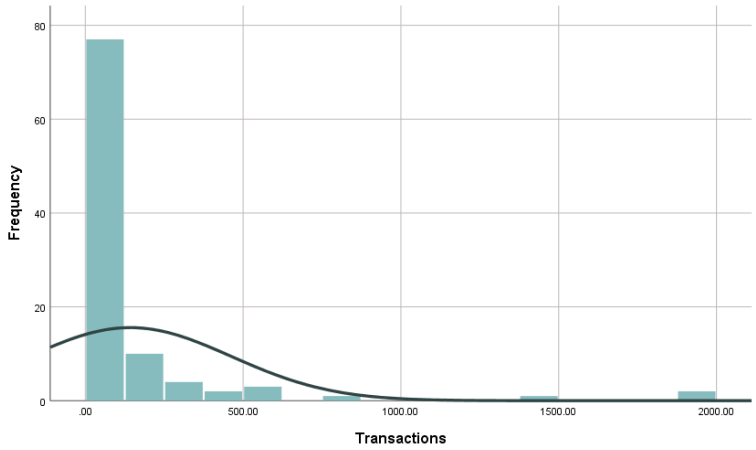


Figura 4. Histograma aferentă setului de 100 de tranzacții

Deși în practica statistică datele puternic asimetrice sunt adesea transformate (de exemplu, prin logaritmare) pentru a reduce impactul valorilor extreme înainte de clusterizare, în acest studiu s-a optat pentru păstrarea datelor în formatul brut. În contextul detectării fraudelor, valorile extreme din „coada” distribuției nu reprezintă un zgomot statistic ce trebuie corectat, ci exact comportamentul atipic (tranzacțiile de valoare foarte mare) pe care sistemul trebuie să îl izoleze. O transformare logaritmică ar reduce distanța dintre plățile de rutină și cele excepționale, reducând sensibilitatea modelelor HMM la anomalii.

Extinderea eșantionului la 500 de tranzacții menține tiparul asimetric al comportamentului financiar, dar aduce o ușoară stabilizare structurală a datelor. Astfel, deși pragul sub care se află 75% dintre tranzacții (Q3) crește ușor, de la 101,5 RON la 131 RON, acesta rămâne în continuare redus, fapt care confirmă că majoritatea plăților se mențin în zona valorilor mici. În plus, deși valoarea maximă urcă la 1983 RON, coeficientul de asimetrie scade de la 4,29 la 3,84. Această diminuare demonstrează că, la un volum mai mare de date, impactul tranzacțiilor excepționale se reduce, făcând eșantionul mai stabil și mai puțin sensibil la valori extreme individuale. Forma distribuției pentru acest volum de date este redată în următoarea figură:

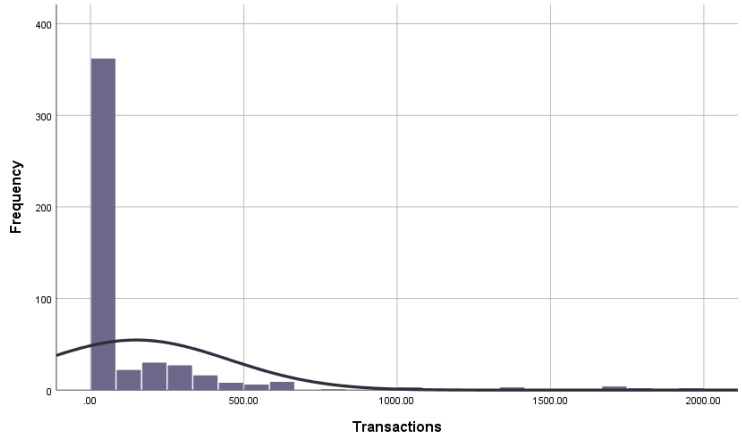


Figura 5. Histograma aferentă setului de 500 de tranzacții

Validarea caracterului realist al datelor simulate este confirmată și de analiza volumului financiar agregat. Pentru eșantionul de 100 de observații (estimat a acoperi un comportament tranzacțional de aproximativ trei luni) suma totală a cheltuielilor este de 14.222 RON, ceea ce sugerează un buget mediu lunar al utilizatorului de cel puțin 4.741 RON. În mod similar, pentru scenariul extins la 500 de tranzacții (estimat a reflecta activitatea pe parcursul unui an întreg) volumul total atinge 74.505 RON, corespunzător unui venit lunar de minimum 6.209 RON. Deși aceste valori nu reprezintă exact salariul mediu brut pe economie, ele conturează profiluri financiare plauzibile și generale.

În concluzie, analiza descriptivă confirmă că ambele seturi de date sunt valide pentru antrenarea eficientă a modelelor HMM, justificând pe deplin ponderile utilizate în procesul de generare.

3.2 Evaluarea numărului optim de stări (TwoStep Cluster)

Pentru a valida numărul de stări necesare modelului Multinomial, s-a rulat algoritmul TwoStep Cluster pe ambele seturi de date. Pentru eșantionul de 100 de tranzacții, algoritmul a identificat

automat 3 clustere ca fiind structura optimă, generând un coeficient Silhouette în zona „Good” (Figura 6). Această evaluare independentă confirmă validitatea teoretică a împărțirii comportamentului în cele trei stări: Low, Medium, High.

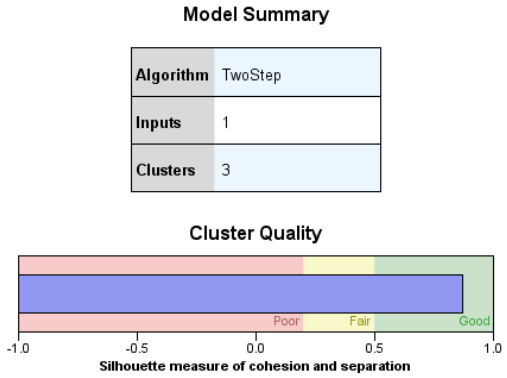


Figura 6. Algoritmul TwoStep Cluster pe setul de 100 de tranzacții

Pentru eșantionul extins de 500 de tranzacții, algoritmul a sugerat o grupare în doar 2 clustere. Această reducere este un fenomen statistic cauzat de creșterea volumului datelor, care diminuează diferențele dintre tranzacțiile medii și cele mari. Totuși, pentru a menține consistența metodologică între cele două scenarii și pentru a nu pierde precizia necesară detectării anomaliilor de valoare ridicată, s-a decis impunerea manuală a parametrului k=3. Rularea forțată pe 3 clustere a menținut un scor Silhouette optim, demonstrând că partiția rămâne validă.

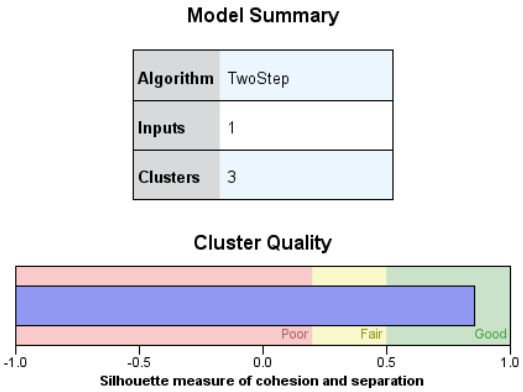


Figura 7. Algoritmul TwoStep Cluster pe setul de 500 de tranzacții

3.3 Discretizarea datelor și stabilirea clusterelor

Deși datele au fost generate inițial pe baza unor limite fixe, această delimitare nu garantează o segmentare optimă a tranzacțiilor în cele trei stări finale (Low, Medium, High). Pentru a obține o grupare adaptată obiectiv eșantionului, s-a aplicat algoritmul K-Means. Această etapă de discretizare a transformat sumele brute în categorii discrete (L, M, H), asigurând astfel formatul de intrare necesar pentru modelul HMM Multinomial.

Tabel 3. Centrele inițiale ale clusterelor (100 de observații)

Cluster	*1*	*2*	*3*
Tranzacții	838	1.921	1

Tabelul 3 prezintă centrele inițiale utilizate ca puncte de pornire de algoritmul K-Means. Se observă astfel că primul cluster a fost inițializat cu o valoare medie (838), al doilea cu o valoare ridicată (1.921), iar cel de-al treilea captează tranzacțiile de valoare mică (1)

Tabel 4. Istoricul iterațiilor (100 de observații)

	Modificarea centrelor clusterelor		
Iterație	1	2	3
1	202,25	174,66	68,24
2	103,03	0	10,87
3	48,93	0	5,77
4	21,37	0	2,49
5	0	0	0

Progresul procesului de clusterizare este reflectat in tabelul Istoricul iterațiilor. Prima iteratie a algoritmului a produs diferențe semnificative în centrele clusterelor, apoi s-au stabilizat la a 5-a iterație. Acest lucru sugerează faptul că centroizii finali sunt valizi.

Tabel 5. Rezultatele algoritmului K-Means (100 de observații)

Simbol observație	$O_1 = L$	$O_2 = M$	$O_3 = H$
Centroid	$c_L = 50,1$	$c_M = 462,4$	$c_H = 1.746,33$
Procentul din totalul tranzacțiilor	87	10	3

În mod similar, algoritmul a fost aplicat pe setul extins de 500 de observații.

Tabel 6. Rezultatele algoritmului K-Means (500 de observații)

Simbol observație	$O_1 = L$	$O_2 = M$	$O_3 = H$
Centroid	$c_L = 40,29$	$c_M = 362$	$c_H = 1.479,05$
Procentul din totalul tranzacțiilor	79,4	16,8	3,8

Se observă că majoritatea tranzacțiilor se concentrează în clusterul tranzacțiilor mici (L). Această distribuție este rezultatul direct al modului în care a fost generat setul de date, pentru a simula un utilizator care efectuează preponderent plăți de rutină. Structura datelor permite modelelor HMM să identifice tranzacțiile din categoriile M (clusterul tranzacțiilor medii) și H (clusterul tranzacțiilor mari) ca fiind evenimente rare în cadrul acestui istoric, oferind baza necesară pentru antrenarea algoritmului pe profilul de cheltuieli generat.

Într-un final, validând clusterizarea, am putut atașa etichete (L, M, H) fiecărei tranzacții. Repartizarea a fost vizualizată în figurile următoare.

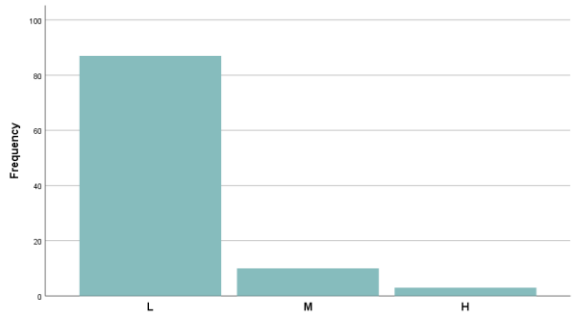


Figura 8. Frecvența tranzacțiilor pe clustere (100 de observații)

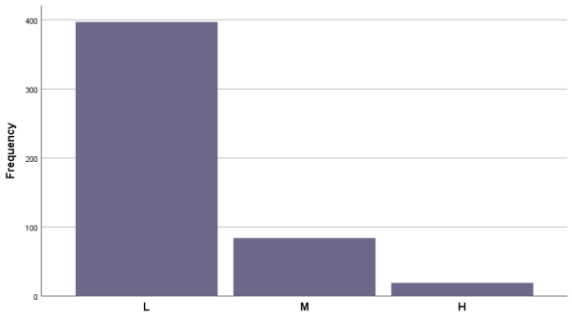


Figura 9. Frecvența tranzacțiilor pe clustere (500 de observații)

3.4 Estimarea parametrilor: exemplu practic

În acest subcapitol este prezentat un exemplu practic, care ilustrează modul în care alternează pașii interdependenți E (Estimare) și M (Maximizare). Pentru a oferi o explicație cât mai intuitivă a procesului de reestimare, am optat pentru o abordare conceptuală simplificată, inspirată din exemplul prezentat în pagina „Baum–Welch algorithm" de pe platforma Wikipedia, în care parametrii sunt actualizați pe baza traseului optim al fiecărei perechi de observații. Deși această variantă diferă de implementarea matematică riguroasă a algoritmului Baum-Welch, care calculează contribuțiile ponderate ale tuturor traseelor posibile prin procedura Forward-Backward, ea servește scopului de a clarifica mecanismul de bază.

Deși modelul dezvoltat în studiul de caz utilizează trei stări ascunse pentru a reflecta fidel profilul de consum al utilizatorului, iar în aplicațiile complexe numărul acestor stări poate fi mult mai mare, reducerea dimensiunii este necesară pentru a exemplifica mecanismul de funcționare al algoritmului. Creșterea numărului de stări ascunse crește exponențial numărul de rute posibile și mărimea tabelelor, făcând urmărirea lor manuală extrem de dificilă.

În cadrul acestui exemplu, cele două stări latente care modelează comportamentul financiar legitim, sunt definite astfel: starea 1 reprezintă cheltuielile destinate necesităților, iar starea 2 le include pe cele destinate dorințelor. În modelul multinomial, starea 1 emite cu precădere extremele L (mici) și H (mari), reprezentând cumpărături zilnice, respectiv chirii sau rate, ceea ce în modelul gaussian se traduce printr-o abatere standard mare. Pe de altă parte, starea 2 emite predominant observații M (medii), precum achiziții ocazionale pentru vacanțe sau electrocasnice, aspect care în modelul gaussian se reflectă printr-o abatere standard mică, sumele fiind mai concentrate în jurul mediei.

Pentru a facilita demonstrația matematică și a face calculele ușor de urmărit, acest exemplu practic este construit pentru modelul Multinomial, utilizând setul de observații discrete (L, M, H). Deși în cazul modelului Gaussian algoritmul optimizează alți parametri

(media și abaterea standard), logica iterativă a pașilor de Estimare și Maximizare rămâne conceptual identică.

3.4.1 Definirea parametrilor inițiali

Pentru demararea algoritmului Baum-Welch, este necesară stabilirea unor valori inițiale aproximative pentru parametrii modelului. În conformitate cu logica comportamentală descrisă, parametrii inițiali sunt definiți prin vectorul probabilităților inițiale (π), matricea de tranziție (A) și matricea de emisie (B).

Deoarece cumpărăturile destinate necesităților zilnice sunt mult mai frecvente, modelul pornește cu o probabilitate mai ridicată pentru starea de rutină: $P(S_1) = 0,7$ (70% șanse ca utilizatorul să fie în starea de Necesități), $P(S_2) = 0,3$ (30% șanse ca utilizatorul să fie în starea de Dorințe).

Matricea de tranziție reflectă probabilitatea ca utilizatorul să rămână în aceeași stare sau să treacă în cealaltă de la o tranzacție la alta. Pentru că starea de rutină domină comportamentul, probabilitatea de a rămâne în starea 1 este ridicată, în timp ce starea 2 tinde să revină la starea 1.

Tabel 7. Matricea de tranziție

	S_1	S_2
S_1	0,8	0,2
S_2	0,6	0,4

Matricea de emisie, care face legătura dintre stările ascunse și valorile observate ale tranzacțiilor (L, M, H), respectă ponderile stabilite pentru cele două profiluri:

Tabel 8. Matricea de emisie

	L	M	H
S_1	0,7	0,1	0,2
S_2	0,1	0,7	0,2

3.4.2 Secvența de observații și calculul rutelor intermediare

Considerăm o secvență de test formată din cinci observații consecutive: L, L, M, H, L. Din acest istoric rezultă următoarea succesiune de tranziții directe între plăți: LL, LM, MH, HL. Pasul următor constă în reestimarea matricei de tranziție. De exemplu, probabilitatea de a observa secvența de tranzacții LL presupunând că utilizatorul se află inițial în starea de Necesități (S_1), iar ulterior trece în starea de Dorințe (S_2), se determină prin relația:

$$P(S_1) \cdot P(L|S_1) \cdot P(S_1 \rightarrow S_2) \cdot P(L|S_2)$$

Înlocuind cu valorile din matricele inițiale pentru prima pereche observată (LL), obținem:

$$0{,}7 \cdot 0{,}7 \cdot 0{,}2 \cdot 0{,}1 = 0{,}0098$$

Acest calcul reprezintă probabilitatea de a observa LL strict în cazul în care sistemul trece de la S_1 la S_2. Totuși, acest procedeu trebuie repetat pentru toate trecerile posibile de la o stare la alta. Așadar, pentru secvența LL, avem următoarele probabilități aferente fiecărei perechi de stări:

$$S_1 \to S_1 => 0{,}7 \cdot 0{,}7 \cdot 0{,}8 \cdot 0{,}7 = 0{,}2744$$
$$S_1 \to S_2 => 0{,}7 \cdot 0{,}7 \cdot 0{,}2 \cdot 0{,}1 = 0{,}0098$$
$$S_2 \to S_1 => 0{,}3 \cdot 0{,}1 \cdot 0{,}6 \cdot 0{,}7 = 0{,}0126$$
$$S_2 \to S_2 => 0{,}3 \cdot 0{,}1 \cdot 0{,}4 \cdot 0{,}1 = 0{,}0012$$

Calcularea acestor probabilități intermediare reflectă la nivel practic Pasul E (Estimarea). Prin acest proces, modelul deduce probabilitatea ca sistemul să fi tranzitat anumite stări ascunse (Necesități sau Dorințe) pe baza exclusivă a observațiilor.

Extrăgând valoarea aferentă tranziției de la S_1 la S_2 (pentru actualizarea acesteia) și identificând perechea care a generat cea mai mare probabilitate totală ($S_1 \to S_1$), putem construi tabelul de analiză pentru întregul șir de tranzacții:

Tabel 9. Tabelul de analiză pentru întregul șir de tranzacții

Secvența observată	*Probabilitatea de a observa secvența dacă starea este S_1 apoi S_2*	*Cea mai mare probabilitate de a observa acea secvență (traseul optim)*
LL	0,0098 = 0,7 × 0,7 × 0,2 × 0,1	0,2744 → S_1, S_1
LM	0,0686 = 0,7 × 0,7 × 0,2 × 0,7	0,0686 → S_1, S_2
MH	0,0028 = 0,7 × 0,1 × 0,2 × 0,2	0,0252 → S_2, S_1
HL	0,0028 = 0,7 × 0,2 × 0,2 × 0,1	0,0784 → S_1, S_1
Total	0,084	0,4466

Astfel, pe baza sumelor obținute în tabel, noua estimare pentru tranziția de la S_1 la S_2 se determină prin raportarea probabilității specifice la probabilitatea maximă totală:

$$P(S_1 \to S_2) = \frac{0{,}084}{0{,}4466} = 0{,}188$$

Această valoare reprezintă o „pseudo-probabilitate". Urmând aceeași logică de calcul, se obțin estimările pentru restul posibilităților de tranziție ($S_1 \to S_1$, $S_2 \to S_1$ și $S_2 \to S_2$), definind prima formă intermediară a matricei de tranziție:

Tabel 10. Matricea de tranziție (Pseudo-probabilități)

	S_1	S_2
S_1	0,9028	0,188
S_2	0,145	0,0644

Mai departe, algoritmul trece la reestimarea parametrilor matricei de emisie (B). Pentru fiecare stare latentă, se determină probabilitatea de a genera categoriile de tranzacții L, M și H. Pentru a ilustra acest mecanism, este exemplificat detaliat calculul pseudo-probabilității pentru emisia simbolului L din starea latentă S_2, valoare notată prin $P(L|S_2)$:

Tabel 11. Calculul pseudo-probabilității $P(L|S_2)$

Secvența observată	*Cea mai mare probabilitate de a observa acea secvență dacă se presupune că L provine din S_2*	*Cea mai mare probabilitate de a observa acea secvență (traseul optim)*
LL	0,0126 → S_2, S_1	0,2744 → S_1, S_1
LM	0,0084 → S_2, S_2	0,0686 → S_1, S_2
HL	0,0028 → S_1, S_2	0,0784 → S_1, S_1
Total	0,0238	0,4214

Pe baza sumelor agregate în tabelul anterior, noua estimare intermediară pentru emisia simbolului L din starea latentă S_2 determină prin raportul direct dintre totalul maximelor condiționate și totalul maximelor absolute ale secvențelor relevante:

$$P(L|S_2) = \frac{0{,}0238}{0{,}4214} = 0{,}0565$$

Acest algoritm permite configurarea întregii matrice de emisie prin izolarea și însumarea probabilităților specifice fiecărei secvențe observate. Repetând aceeași procedură pentru emisiile de tip M și H în cazul ambelor stări latente, se obține structura completă a noilor parametri intermediari:

Tabel 12. Matricea de emisie (Pseudo-probabilități)

	L	M	H
S_1	1	0,5373	1
S_2	0,0565	1	0,4054

Deoarece în cadrul unei matrice de tranziție sau de emisie suma probabilităților de pe fiecare rând trebuie să fie strict egală cu 1, pasul final constă în normalizarea acestor pseudo-probabilități (împărțirea fiecărei valori la suma rândului corespunzător). Acest procedeu constituie Pasul M (Maximizarea) din cadrul teoretic. Practic, noile matrice sunt actualizate aplicând principiul verosimilității maxime (MLE) asupra estimărilor obținute la pasul anterior, tratându-le pe acestea din urmă ca fiind date certe. Procesul de actualizare finală este reflectat în tabelele de mai jos:

Tabel 13. Matricea de tranziție (Normalizată)

	S_1	S_2
S_1	0,8276	0,1724
S_2	0,6924	0,3076

Tabel 14. Matricea de emisie (Normalizată)

	L	M	H
S_1	0,3941	0,2118	0,3941
S_2	0,0386	0,684	0,2773

Aceste etape se repetă iterativ pe întregul set de date până la convergența algoritmului, moment în care parametrii modelului HMM se stabilizează și nu mai suferă modificări semnificative.

3.5 Analiza parametrilor modelelor

În această etapă, am extras parametrii principali ai modelelor HMM antrenate, notați prin setul forma $\lambda = \{A, B, \pi\}$. Vectorul probabilităților inițiale (π) nu este relevant pentru analiza de față, deoarece indică doar starea în care se află prima tranzacție din setul de date sintetice. Prin urmare, analiza se va concentra pe matricea de tranziție (A), care descrie dinamica trecerii sistemului între stările latente, și pe parametrul de emisie (B), care stabilește legătura probabilistă între stările ascunse și valorile observate.

3.5.1 Parametrii modelului Gaussian

În cazul modelului Gaussian, matricea de emisie conține parametrii distribuției de probabilitate aferente fiecărei stări latente, reprezentând în mod specific valoarea medie și abaterea standard a sumelor tranzacționate.

Pentru eșantionul analizat, algoritmul a generat următoarea matrice de emisie (B), unde Starea 1 corespunde tranzacțiilor mici, Starea 2 celor medii, iar Starea 3 celor mari:

$$B = \begin{bmatrix} 29{,}849 & 14{,}531 \\ 159{,}902 & 81{,}509 \\ 825{,}208 & 598{,}938 \end{bmatrix}$$

Analizând profilul tranzacțiilor medii (Starea 2), observăm că valorile urmează o distribuție normală cu media $\mu = 159{,}9$ RON și abaterea standard $\sigma = 81{,}5$ RON. Această distribuție este ilustrată în graficul următor:

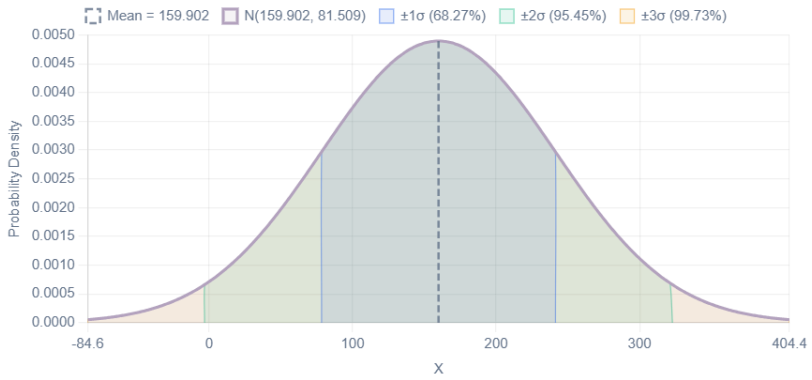


Figura 10. Distribuția normală a tranzacțiilor din Starea 2

Așa cum reiese din reprezentarea grafică, majoritatea valorilor se concentrează în zona centrală. Suprafața evidențiată cu albastru delimitează intervalul de plus/minus o abatere standard față de medie ($[\mu - \sigma, \mu + \sigma]$). Acest lucru indică faptul că sumele cuprinse în această zonă au cea mai mare probabilitate de a fi generate atunci când utilizatorul se află în Starea 2.

Prin contrast, se observă o suprapunere semnificativă între distribuțiile aferente Stării 2 și Stării 3:

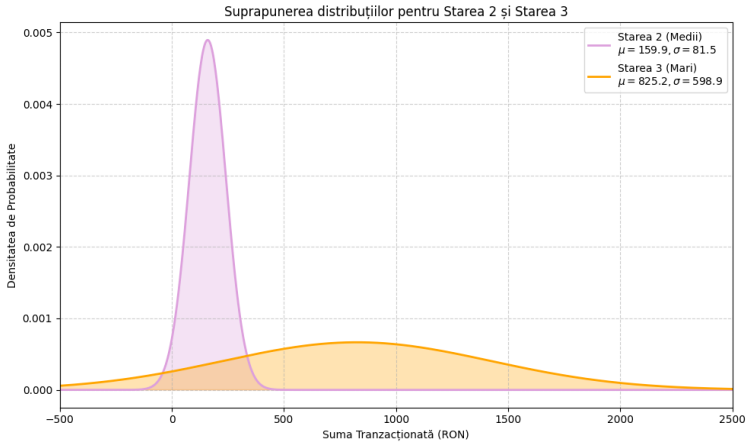


Figura 11. Suprapunerea distribuțiilor pentru Starea 2 și Starea 3

Având o abatere standard masivă (598,93 RON), distribuția Stării 3 se extinde puternic spre zona inferioară, acoperind complet intervalul valoric aferent tranzacțiilor medii. Din cauza acestei suprapuneri extinse, modelul tinde să facă o confuzie între cele două stări atunci când clasifică tranzacțiile aflate în această zonă comună de valori.

Dinamica dintre aceste stări este guvernată de matricea de tranziție (A). Fiecare linie și coloană reprezintă o stare latentă, iar intersecțiile arată probabilitatea trecerii de la un profil de cheltuieli la altul:

$$A = \begin{bmatrix} 0,673 & 0,216 & 0,112 \\ 0,847 & 0,153 & 0 \\ 0,601 & 0,097 & 0,301 \end{bmatrix}$$

Se observă că Starea 1 domină activitatea financiară, deoarece din oricare altă stare există o probabilitate majoritară ca utilizatorul să se întoarcă la aceasta (84,7% din Starea 2 și 60,1% din Starea 3). Totodată, confuzia generată de suprapunerea distribuțiilor se reflectă direct în matricea de tranziție: există o probabilitate neobișnuit de mare (30,1%) ca utilizatorul să rămână ancorat în Starea 3, sugerând că, la acest volum de date, modelul grupează eronat unele tranzacții medii ca fiind generate de starea specifică cheltuielilor ridicate.

Acest comportament se ajustează semnificativ în cazul modelului antrenat pe 500 de tranzacții. Odată cu creșterea volumului de date, algoritmul reușește să facă o distincție mult mai clară între nivelurile sumelor tranzacționate (medii și mari), diminuând impactul suprapunerii:

$$A = \begin{bmatrix} 0,701 & 0,252 & 0,047 \\ 0,691 & 0,276 & 0,033 \\ 0,788 & 0,212 & 0 \end{bmatrix}, B = \begin{bmatrix} 29,370 & 14,075 \\ 272,511 & 151,515 \\ 1412,613 & 378,203 \end{bmatrix}$$

Rafinarea parametrilor este evidentă în noua matrice de tranziție. Spre deosebire de eșantionul precedent, se observă că probabilitatea de a face o tranziție către Starea 3 dintr-o altă stare este foarte scăzută (doar 4,7% din Starea 1 și 3,3% din Starea 2). Mai mult, probabilitatea de a rămâne ancorat în Starea 3 a devenit 0. Acest fapt demonstrează că algoritmul tratează acum corect cheltuielile majore ca fiind evenimente mai degrabă izolate, după care utilizatorul tinde să revină la profilul tranzacțiilor de valoare redusă.

3.5.2 Parametrii modelului Multinomial

În cadrul modelului multinomial, parametrul de emisie (B) indică probabilitatea de apariție a simbolurilor discrete (L, M, H) în fiecare stare ascunsă.

Pentru modelul antrenat pe setul de 100 de tranzacții, parametrii obținuți sunt următorii:

$$A = \begin{bmatrix} 0,597 & 0,403 & 0 \\ 0,177 & 0,575 & 0,249 \\ 0,761 & 0,001 & 0,239 \end{bmatrix}, B = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0,039 & 0,74 & 0,222 \end{bmatrix}$$

În acest scenariu, se observă o limitare clară a algoritmului cauzată de volumul redus de date. Matricea de emisie (B) arată că stările 1 și 2 sunt identice din punct de vedere funcțional, ambele emițând exclusiv simbolul aferent tranzacțiilor mici (L) cu o probabilitate de 100%. Starea 3 captează tranzacțiile medii (cu o probabilitate de 74%) și mari (cu 22,2%), dar probabilitatea de a rămâne în această stare este redusă (23,9%, conform matricei A). Algoritmul

nu are suficiente date pentru a distinge corect diferitele categorii de plăți, ajungând să grupeze plățile de rutină sub două stări redundante.

Odată cu creșterea volumului de observații la 500 de tranzacții, se observă o dinamică mai clară a modelului Multinomial. Pentru modelul antrenat pe 500 de tranzacții, parametrii sunt următorii:

$$A = \begin{bmatrix} 0{,}366 & 0{,}408 & 0{,}226 \\ 0{,}152 & 0{,}163 & 0{,}685 \\ 0{,}093 & 0{,}311 & 0{,}596 \end{bmatrix}, B = \begin{bmatrix} 0{,}423 & 0{,}577 & 0 \\ 0{,}599 & 0{,}268 & 0{,}133 \\ 0{,}990 & 0{,}009 & 0 \end{bmatrix}$$

Deoarece majoritatea plăților din istoric (79,4%) aparțin clusterului tranzacțiilor mici, modelul asociază logic o probabilitate dominantă pentru emiterea simbolului L în starea 3 (99%). Starea 1 devine responsabilă pentru recunoașterea tranzacțiilor medii (probabilitate de 57,7% pentru M), în timp ce starea 2 asimilează plățile cu sume mari (probabilitate de 13,3% pentru H). Această diferențiere, lipsită în modelul antrenat pe 100 de observații, evidențiază faptul că un volum mai mare de date permite algoritmului să capteze mai bine nuanțele comportamentului financiar.

3.6 Simularea detaliată a unei alerte

Evaluarea modelelor s-a făcut folosind metoda ferestrei glisante (sliding window). Această tehnică analizează fiecare tranzacție nouă punând-o în contextul istoricului recent. Mai exact, algoritmul calculează probabilitatea logaritmică (log-likelihood) a secvenței pentru a vedea cât de bine se potrivește aceasta cu profilul obișnuit de cheltuieli.

Dimensiunea ferestrei a fost menținută la 15 tranzacții pentru ambele modele, asigurând un echilibru optim între sensibilitate și stabilitate. O fereastră prea scurtă ar face scorul log-likelihood extrem de susceptibil la zgomot, deoarece valoarea sa s-ar modifica masiv la apariția unei plăți legitime de o valoare mai ridicată, generând astfel alarme false. În schimb, o fereastră prea lungă ar dilua semnalul anomaliei, făcând ca o tranzacție frauduloasă să se piardă în media volumului mare de operațiuni normale și să nu mai atingă pragul critic de alertă.

Extragerea secvențelor a început de la prima observație, generând exact 86 de ferestre distincte, aceasta fiind limita matematică impusă de eșantionul mai mic (100-15+1=86). Prin standardizarea dimensiunii și a numărului de ferestre de testare, am asigurat o comparabilitate directă a indicatorilor de performanță, izolând variabilă care diferă între experimente: dimensiunea setului de date de antrenament.

Pentru a testa practic detecția, am evaluat secvențele de tranzacții în două scenarii: o dată în forma lor originală, iar apoi introducând forțat o anomalie pe ultima poziție. Pentru modelul

Gaussian am utilizat valoarea de 1.500 RON (reprezentând o valoare medie din categoria de tranzacții mari), în timp ce pentru modelul Multinomial am utilizat eticheta „H”.

Pentru a ilustra modul în care sistemul ia decizia de a bloca o tranzacție în timp real, vom analiza un exemplu practic la nivel de secvență, aplicând principiul ferestrei glisante. Demonstrația utilizează parametrii modelului Gaussian antrenat pe eșantionul de 100 de observații.

Să presupunem că extragem din istoricul utilizatorului cea mai recentă secvență disponibilă, formată din tranzacțiile de la poziția 86 până la 100 (conform Tabelului 1). Aceste sume reflectă un comportament legitim.

Sistemul analizează această secvență curentă ($O_{bază}$) pentru a stabili nivelul de normalitate:

$$O_{bază} = \{143, 17, 18, 73, 7, 19, 51, 36, 26, 306, 37, 46, 5, 418, 2\}$$

Modelul HMM Gaussian preia această succesiune și calculează scorul de log-verosimilitate (log-likelihood), obținând valoarea de -81,8565. Matematic, probabilitatea brută de acceptare a secvenței de către model, notată cu α_1, se determină calculând exponențiala scorului logaritmic ($e^{log-likelihood}$):

$$\alpha_1 = 2{,}819 \times 10^{-36}$$

Deși această valoare este extrem de mică în termeni absoluți, ea reprezintă scorul de referință pentru secvența cu tranzacții legitime.

Se inițiază o nouă tranzacție la momentul t+1, în valoare de 1500 RON. Pentru a o evalua, sistemul glisează fereastra cu o poziție: prima tranzacție (143 RON) este eliminată, iar noua sumă (1500 RON) este adăugată la final. Noua secvență ($O_{nouă}$) devine:

$$O_{nouă} = \{17, 18, 73, 7, 19, 51, 36, 26, 306, 37, 46, 5, 418, 2, 1500\}$$

Modelul calculează acum probabilitatea pentru noua secvență (α_2). Întrucât valoarea de 1500 RON reprezintă o deviație masivă de la comportamentul de rutină, probabilitatea scade:

$$\alpha_2 = 9{,}259 \times 10^{-38}$$

Pentru a stabili dacă declanșează o alertă de fraudă, sistemul analizează diferența dintre cele două probabilități ($\Delta\alpha = \alpha_1 - \alpha_2$). Ulterior, se calculează variația procentuală a verosimilității ($\frac{\Delta\alpha}{\alpha 1}$):

$$\frac{\Delta\alpha}{\alpha_1} = 0{,}97$$

Dacă banca a setat un prag de decizie de 70%, algoritmul compară variația obținută cu acest prag. Deoarece scăderea verosimilității este majoră, tranzacția de 1.500 RON este

etichetată drept tentativă de fraudă (Adevărat Pozitiv). Plata este blocată, iar suma nu este inclusă în istoricul de tranzacții, prevenind coruperea tiparului învățat.

Pentru a evalua secvențele legitime și a stabili rata alarmelor false, se aplică exact același principiu. În acest scenariu, α_1 reprezintă probabilitatea ferestrei curente, iar α_2 se calculează pentru următoarea fereastră glisantă din șirul de date (unde se elimină prima tranzacție și se adaugă noua observație, de această dată legitimă). Deoarece tranzacția se încadrează în tiparul obișnuit de cheltuieli, variația procentuală a verosimilității va fi mai mică decât pragul de decizie. Prin urmare, sistemul clasifică tranzacția ca fiind corectă (Adevărat Negativ), o autorizează și o include definitiv în istoric, permițând actualizarea continuă a profilului utilizatorului.

3.7 Rezultatele detecției de anomalii

Preluând același principiu de calcul, scorurile de log-verosimilitate generate de algoritm pentru toate cele 86 de ferestre au fost prelucrate ulterior în Excel. Aici au fost calculate variațiile procentuale, testând răspunsul sistemului la trei niveluri ale pragului: 50%, 70% și 90%. Prin compararea rapoartelor obținute cu aceste valori, am clasificat răspunsul sistemului pentru fiecare fereastră în parte (TP, FP, TN, FN), agregând datele finale pentru a construi matricele de confuzie aferente fiecărui model.

Tabel 15. Matricea de confuzie aferentă modelului Multinomial

	100 de observații				*500 de observații*			
	TP	FN	FP	TN	TP	FN	FP	TN
50%	83	3	9	76	85	1	12	73
70%	76	10	8	77	85	1	9	76
90%	76	10	2	83	69	17	1	84

Tabel 16. Matricea de confuzie aferentă modelului Gaussian

	100 de observații				*500 de observații*			
	TP	FN	FP	TN	TP	FN	FP	TN
50%	79	7	25	60	83	3	22	63
70%	79	7	20	65	83	3	19	66
90%	76	10	15	70	75	11	16	69

Ambele modele demonstrează o capacitate de adaptare la ajustarea parametrilor de prag. Pe eșantionul de 500 de observații, modelul Gaussian își păstrează o rată de detecție robustă pe măsură ce pragul crește de la 50% la 90% (TP scade doar de la 83 la 75), reușind în același timp să diminueze semnificativ numărul alarmelor false (FP scade de la 22 la 16). În contrast, modelul Multinomial manifestă o tendință mult mai restrictivă la pragul de 90%: deși reușește să reducă alarmele false la o valoare minimă (FP scade de la 12 la 1), această rigurozitate atrage

o penalizare pronunțată a ratei de detecție, capacitatea de identificare a anomaliilor scăzând de la 85 la 69 (TP).

În contextul securității bancare, optimizarea performanței unui model de detecție a anomaliilor reprezintă un echilibru delicat între două obiective: maximizarea ratei de detecție și minimizarea alarmelor false. Importanța unei rate ridicate a Adevăratelor Pozitive (TP) este evidentă, fiind esențială pentru protejarea activelor clienților. O capacitate sporită de a identifica și bloca rapid tentativele de fraudă limitează daunele directe și previne pierderile financiare. Cu toate acestea, minimizarea Falselor Pozitive (FP) este la fel de critică pentru menținerea încrederii și a satisfacției clienților. Blocarea eronată a unui card pentru tranzacții legitime are un impact negativ major asupra activității cotidiene a utilizatorului, care poate ajunge să perceapă serviciile băncii ca fiind lipsite de siguranță sau chiar să renunțe la produsele acesteia. Prin urmare, succesul unui astfel de sistem depinde de capacitatea sa de a filtra fraudele cu precizie, fără a afecta experiența unui client legitim.

3.8 Evaluarea performanței globale

Evaluarea performanței globale a modelelor implementate se realizează prin intermediul curbei ROC și a ariei de sub această curbă (AUROC). Curba ROC ilustrează grafic compromisul dintre rata detecțiilor corecte (TPR) și rata alarmelor false (FPR) la diferite praguri de alertă.

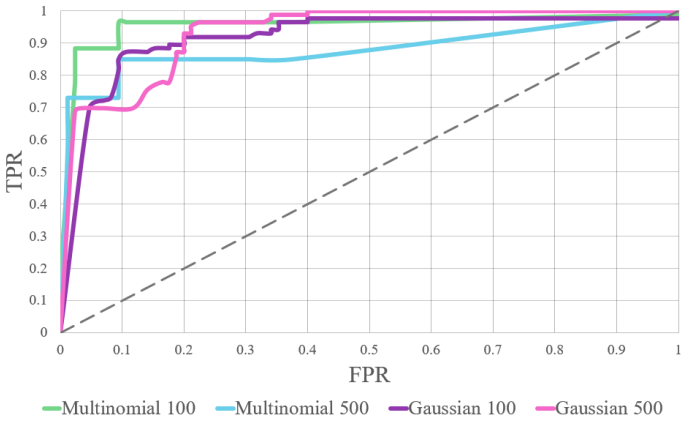


Figura 12. Curba ROC

Analiza vizuală a curbelor demonstrează o performanță ridicată pentru toate cele patru variante testate, formele acestora fiind puternic orientate spre colțul din stânga-sus. Pentru o departajare cantitativă precisă, s-a calculat aria de sub curbă.

Tabel 17. Valorile indicatorului AUROC

Multinomial 100	0.9538
Multinomial 500	0.8781

Gaussian 100	0.9165
Gaussian 500	0.9284

Conform datelor obținute, performanța modelelor variază semnificativ în funcție de dimensiunea eșantionului de antrenament. Modelul Multinomial înregistrează cea mai ridicată valoare AUROC pe eșantionul redus, dar înregistrează o scădere notabilă a preciziei odată cu creșterea volumului de date. În schimb, modelul Gaussian prezintă o evoluție inversă, oferind rezultate mai stabile și mai bune pe eșantionul extins. În ansamblu, ambele configurații demonstrează o capacitate solidă de detectare a anomaliilor.

Deși valorile AUROC sunt foarte apropiate, analiza formei curbelor ROC din Figura 12 evidențiază o diferență importantă legată de flexibilitate între cele două abordări. Curbele aferente modelelor Multinomial au o formă pronunțată de scară. Această rigiditate grafică arată că o modificare minoră a pragului de alertă poate schimba drastic performanța sistemului, provocând salturi bruște ale ratei de detecție sau ale alarmelor false. În contrast, curbele modelelor Gaussian au o creștere mult mai fluidă. Această formă continuă demonstrează flexibilitatea superioară a modelului Gaussian, care permite o ajustare fină și treptată a sensibilității, fără riscul unor fluctuații extreme în clasificarea tranzacțiilor.

Un alt aspect esențial în evaluarea modelelor este impactul lungimii eșantionului asupra resurselor computaționale. Așa cum s-a observat, extinderea istoricului de la 100 la 500 de tranzacții nu aduce o creștere a performanței AUROC care să justifice efortul de calcul suplimentar. Decizia de a nu extinde istoricul este susținută și de constatările lui Srivastava et al. (2008), care avertizează că timpul de antrenare a modelului crește abrupt pentru secvențe mai mari de 100 de observații. Întrucât o instituție emitentă trebuie să antreneze modele HMM individuale pentru milioane de clienți și să emită zilnic noi carduri, scalabilitatea întregului sistem depinde direct de minimizarea acestui timp de procesare.

3.9 Selecția modelului optim

Selecția variantei optime pentru implementarea operațională a constat în testarea a două ipoteze de compromis.

În primul rând, s-a evaluat dacă un model mai simplu (Multinomial) poate oferi rezultate mai bune. Datele au infirmat această ipoteză: la praguri stricte, modelul Multinomial se dovedește prea rigid, generând un număr inacceptabil de fals negative, în timp ce modelul Gaussian rămâne flexibil și echilibrat.

În al doilea rând, s-a analizat dacă un istoric mai lung (500 de observații) merită compromisul computațional subliniat de Srivastava et al. (2008). Concluzia a fost tot negativă.

Diferențele de performanță globală (ariile AUROC fiind extrem de apropiate) nu justifică efortul computațional și timpul de antrenare suplimentar necesar pentru procesarea a 500 de tranzacții.

Tabelul 18 prezintă o sinteză comparativă a celor patru configurații evaluate, facilitând vizualizarea criteriilor de selecție.

Tabel 18. Sinteza comparativă a modelelor HMM

Criteriu	*Gaussian 100*	*Gaussian 500*	*Multinomial 100*	*Multinomial 500*
AUROC	0,9165	0,9284	0,9538	0,8781
Efort computațional	Redus	Ridicat	Redus	Ridicat
Flexibilitate prag	Ridicată	Ridicată	Redusă	Redusă

În consecință, modelul Gaussian antrenat pe 100 de observații este desemnat drept varianta optimă. Aceasta oferă cel mai bun echilibru între: performanță globală ridicată (AUROC = 0,9165), flexibilitate în ajustarea pragului de decizie fără degradare abruptă a detecției și efort computațional redus. Aceste caracteristici fac din modelul Gaussian 100 alegerea ideală pentru instituțiile financiare ce doresc să implementeze un sistem scalabil de detecție a fraudelor.

Concluzii

Lucrarea a urmărit identificarea unei configurații optimizate a Modelelor Markov cu Stări Ascunse pentru detecția fraudelor financiare. Rezultatele arată că folosirea unui istoric de 500 de tranzacții în loc de 100 nu aduce o îmbunătățire a performanței care să justifice costul computațional. În ceea ce privește tipul emisiilor, modelul Gaussian reprezintă alegerea optimă pentru mediul bancar datorită naturii sale continue. La modelul Multinomial, din cauza structurii discrete, o modificare minoră a pragului de decizie determină schimbări bruște pe grafic. În schimb, modelul Gaussian permite o ajustare fină și treptată a sensibilității. Această flexibilitate le oferă băncilor posibilitatea de a seta cu precizie nivelul acceptat de alarme false, optimizând astfel sistemul de securitate.

Originalitatea cercetării constă în utilizarea lanțurilor Markov, un concept clasic din statistică, în contextul actual al digitalizării bancare. De asemenea, analiza s-a diferențiat prin evaluarea modelelor nu doar pe baza cifrelor de performanță, ci și prin studiul flexibilității lor pe grafic.

Din punct de vedere practic, structura metodologică propusă oferă băncilor o soluție accesibilă și scalabilă pentru verificarea eficientă a tranzacțiilor. Astfel, modelul ajută direct la minimizarea pierderilor financiare într-un mediu în care fenomenul fraudei evoluează constant. Pe de altă parte, datorită flexibilității modelului ales, clienții beneficiază de siguranța fondurilor, evitând blocarea abuzivă a contului în cazul unor abateri minore de la profilul lor obișnuit de cheltuieli.

În ceea ce privește limitările lucrării, principalul dezavantaj este că datele sintetice utilizate nu captează complexitatea reală a fluxurilor financiare. Deoarece în cadrul acestei simulări lipsește o variabilă temporală, cum ar fi ora sau data plăților, aspecte fundamentale precum fluctuațiile sezoniere ale cheltuielilor și comportamentele ciclice nu sunt surprinse de model. Recurgerea la date generate a fost însă necesară, deoarece informațiile bancare reale nu au putut fi accesate din motive de confidențialitate.

Ca perspective viitoare, o primă direcție de cercetare ar putea viza extinderea modelului prin generarea sintetică a unei variabile temporale. Aceasta ar permite simularea sezonalității și a ciclicității specifice datelor financiare reale. O altă perspectivă esențială constă în determinarea matematică a pragului optim de alertă, aplicat specific modelului Gaussian antrenat pe 100 de observații. Un astfel de studiu ar analiza echilibrul dintre costurile verificării alarmelor false și pierderile cauzate de fraudele nedetectate, oferind băncii argumente clare pentru utilizarea lui în practică.

În concluzie, lucrarea demonstrează eficiența Modelelor Markov cu Stări Ascunse în detectarea fraudelor financiare. Metodologia optimizată oferă o soluție scalabilă și echilibrată, capabilă să protejeze fondurile băncii fără a afecta confortul clienților.

Bibliografie

Bacher, J., Wenzig, K. and Vogler, M. (2004). SPSS TwoStep Cluster-a first evaluation.

Bhusari, V. & Patil, S. (2011). Application of hidden markov model in credit card fraud detection. International Journal of Distributed and Parallel Systems, 2(6), 203.

Carlson, L., Navalta, D., Nicolescu, M., Nicolescu, M. and Woodward, G. (2021). Early classification of intent for maritime domains using multinomial hidden markov models. Frontiers in Artificial Intelligence, 4, p.702153.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer.

MacQueen, J., 1967. Multivariate observations. In Proceedings ofthe 5th Berkeley symposium on mathematical statisticsand probability (Vol. 1, pp. 281-297). Oakland, CA, USA: University of California press.

Ng, A. & Ma, T. (2023). CS229 Lecture notes. Stanford University.

Nkemnole, E.B. & Akinsete, A.A. (2021). Hidden Markov Model using transaction patterns for ATM card fraud detection. Theoretical & Applied Economics, 28(4).

Norris, J.R. (1998). Markov chains (No. 2). Cambridge university press.

Rabiner, L. & Juang, B. (2003). An introduction to hidden Markov models. IEEE ASSP Magazine, 3(1), 4-16.

Srivastava, A., Kundu, A., Sural, S. & Majumdar, A. (2008). Credit card fraud detection using hidden Markov model. IEEE Transactions on Dependable and Secure Computing, 5(1), 37-48.

Visser, I. & Speekenbrink, M. (2010). depmixS4: an R package for hidden Markov models. Journal of Statistical Software, 36, 1-21.

*** Asociația Română a Băncilor (ARB) (2024). Comunicat de presă: 57% dintre populația inclusă financiar și 87% dintre companii efectuează plăți prin Internet/Mobile banking.

*** Banca Națională a României (BNR) (2025). Raport asupra stabilității financiare decembrie 2025, 110-113.

*** GeeksforGeeks. Hidden Markov Model in R. https://www.geeksforgeeks.org/machine-learning/hidden-markov-model-in-r/

*** Wikipedia. Baum–Welch algorithm. https://en.wikipedia.org/wiki/Baum%E2%80%93Welch_algorithm

Anexe

Tabelul următor prezintă cele 500 de observații generate conform metodologiei descrise în secțiunea „2.1 Generarea și structurarea datelor”, utilizate pe parcursul lucrării pentru antrenarea modelelor HMM.

Anexa 1.Setul de 500 de tranzacții generate (exprimate în RON)

Nr. tranzactiei	*Suma*	*Nr. tranzactiei*	*Suma*	*Nr. tranzactiei*	*Suma*	*Nr. tranzactiei*	*Suma*	*Nr. tranzactiei.*	*Suma*
1	7	101	298	201	230	301	30	401	37
2	28	102	27	202	3	302	44	402	43
3	1014	103	30	203	36	303	24	403	26
4	26	104	45	204	37	304	42	404	46
5	128	105	33	205	5	305	1354	405	39
6	15	106	132	206	230	306	21	406	16
7	49	107	430	207	46	307	36	407	29
8	15	108	223	208	24	308	38	408	15
9	254	109	32	209	30	309	188	409	1
10	349	110	20	210	1157	310	3	410	20
11	27	111	7	211	603	311	183	411	28
12	32	112	24	212	17	312	36	412	24
13	46	113	18	213	205	313	299	413	10
14	115	114	1731	214	35	314	33	414	18
15	21	115	247	215	34	315	7	415	46
16	44	116	451	216	5	316	37	416	174
17	38	117	11	217	2	317	35	417	321
18	257	118	7	218	157	318	34	418	19
19	49	119	43	219	275	319	43	419	352
20	13	120	27	220	31	320	45	420	219
21	33	121	47	221	18	321	334	421	43
22	46	122	46	222	41	322	241	422	307
23	42	123	113	223	1	323	222	423	11
24	9	124	143	224	47	324	37	424	462
25	43	125	51	225	15	325	326	425	14
26	45	126	102	226	38	326	143	426	33
27	223	127	27	227	49	327	7	427	37
28	14	128	28	228	38	328	5	428	1373
29	37	129	73	229	32	329	360	429	48
30	48	130	44	230	476	330	427	430	637
31	79	131	1062	231	198	331	559	431	51
32	26	132	22	232	16	332	8	432	15
33	46	133	16	233	426	333	176	433	29
34	41	134	37	234	32	334	7	434	20
35	21	135	35	235	42	335	321	435	590
36	29	136	2	236	48	336	16	436	29
37	40	137	197	237	210	337	282	437	47
38	27	138	589	238	32	338	42	438	31

39	13	139	1605	239	43	339	9	439	30
40	160	140	38	240	27	340	41	440	28
41	262	141	7	241	1267	341	49	441	34
42	10	142	37	242	8	342	160	442	47
43	36	143	3	243	34	343	43	443	404
44	20	144	8	244	37	344	21	444	46
45	41	145	48	245	18	345	4	445	807
46	18	146	17	246	72	346	33	446	40
47	505	147	21	247	45	347	38	447	34
48	185	148	18	248	26	348	45	448	592
49	33	149	48	249	607	349	8	449	501
50	239	150	48	250	31	350	37	450	37
51	132	151	26	251	43	351	43	451	39
52	39	152	43	252	27	352	171	452	207
53	14	153	297	253	38	353	35	453	7
54	33	154	3	254	44	354	227	454	69
55	13	155	36	255	14	355	37	455	33
56	216	156	22	256	15	356	45	456	22
57	8	157	337	257	46	357	165	457	348
58	11	158	3	258	22	358	29	458	5
59	1379	159	34	259	45	359	318	459	28
60	40	160	18	260	366	360	302	460	42
61	82	161	40	261	22	361	219	461	177
62	19	162	10	262	36	362	29	462	39
63	338	163	348	263	17	363	1809	463	39
64	289	164	1	264	7	364	8	464	26
65	625	165	403	265	32	365	42	465	27
66	299	166	36	266	41	366	12	466	97
67	44	167	48	267	18	367	40	467	14
68	33	168	30	268	43	368	49	468	40
69	32	169	37	269	37	369	6	469	10
70	23	170	37	270	38	370	33	470	48
71	40	171	38	271	34	371	215	471	33
72	34	172	41	272	269	372	1	472	68
73	114	173	44	273	32	373	35	473	39
74	276	174	107	274	11	374	43	474	91
75	3	175	28	275	166	375	128	475	4
76	1	176	27	276	49	376	37	476	48
77	36	177	1983	277	186	377	45	477	30
78	124	178	306	278	46	378	41	478	487
79	46	179	48	279	23	379	45	479	46
80	33	180	3	280	53	380	17	480	13
81	44	181	12	281	567	381	26	481	29
82	101	182	351	282	41	382	336	482	33
83	186	183	62	283	169	383	1670	483	259
84	23	184	31	284	224	384	107	484	330
85	601	185	20	285	270	385	18	485	346

86	26	186	36	286	32	386	10	486	297
87	27	187	32	287	615	387	7	487	18
88	20	188	263	288	12	388	14	488	27
89	36	189	45	289	21	389	536	489	21
90	509	190	20	290	11	390	995	490	21
91	253	191	82	291	1969	391	26	491	33
92	30	192	3	292	1	392	29	492	40
93	30	193	28	293	13	393	20	493	45
94	15	194	1715	294	178	394	12	494	1692
95	307	195	47	295	42	395	18	495	33
96	42	196	16	296	36	396	43	496	24
97	45	197	41	297	1768	397	1006	497	30
98	40	198	36	298	45	398	2	498	300
99	498	199	363	299	339	399	91	499	32
100	33	200	42	300	1553	400	30	500	55